


Secuencia HTTP y llamadas a Azure


Cliente HTTP: proceso Streamlit. FastAPI coordina Azure con la identidad del usuario.



Rutas UI → API bajo /api/v1; Authorization: Bearer <token API>. La flecha doble resume request + response.

Autenticación: JWT y acceso delegado


Pipeline compartido por documentos y consultas; el secreto de FastAPI autentica el intercambio OBO.



Éxito → clientes por petición. RBAC autoriza después la operación en Search/OpenAI.


Ingestión: del archivo al índice textual

POST /api/v1/documents/upload · Dependencias: JWT → OBO(Search) → FileIngestionService.



Consulta RAG: búsqueda, contexto y modelo

POST /api/v1/queries/answer · Pydantic: question, document_id opcional y top_k.



Scopes, contratos HTTP y límites

Scopes distintos por destinatario. Consentimiento de Entra y roles de datos son controles separados.

Destino del token	Scope solicitado	Control / rol de datos
FastAPI	api://<api-client-id>/access_as_user	aud = client ID API; scp incluye access_as_user
Azure AI Search	https://search.azure.com/.default	Search Index Data Contributor (carga y consulta de la home)
Azure OpenAI	https://cognitiveservices.azure.com/.default	Cognitive Services OpenAI User

CONTRATOS · Prefijo /api/v1 · Respuestas de éxito: HTTP 200

Método y ruta	Entrada / límites	Salida
POST /documents/upload	file: PDF con texto / TXT / MD; ≤ 10 MiB	document_id, source, indexed_chunks, warnings
POST /queries/answer	question: 1-4000 caracteres; top_k: 1-20 (UI: 5); document_id opcional	answer: string; context: SearchHit[]
POST /documents/chunks	chunks: 1-1000; embeddings precalculados	indexed_chunks
POST /queries/search	embedding precalculado; top_k: 1-50; document_id opcional; índice vectorial	matches: SearchHit[]
GET /health	Público; no prueba conexiones con Azure	Estado y configuración