


Visión general de los ocho nodos

Mapa del grafo: las siguientes hojas detallan cada decisión y su interacción con Azure.



START inicia los contadores en 0. Por defecto: hasta 2 búsquedas y 2 generaciones por pregunta.


Búsqueda y simplificación: hoja 3. Contexto: hoja 4. Generación Azure: hoja 5.

rewrite_query simplifica; prepare_context limita; validate_citations comprueba citas. Son reglas de Python.

END devuelve answer y context. Citas: hoja 6. Salidas: hoja 7. Configuración y trazas: hoja 8.

Entrada, identidad y recursos

FastAPI valida el token y prepara Search; OpenAI se abre únicamente cuando se necesita generar.



Ruta: /api/v1/queries/answer; JSON: question, document_id y top_k;
Authorization: Bearer.


Scope: <https://search.azure.com/.default>. RBAC: Search Index Data
Contributor sobre el recurso Search.

JWT: RS256/JWKS, iss, aud, tid y exp; scp contiene access_as_user; azp es
el frontend autorizado.

OBO: token API + secreto. Consentimiento Entra y RBAC son distintos.
OpenAI abre en generate y cierra al salir.

Búsqueda y consulta alternativa

Segunda búsqueda por contexto vacío; la simplificación local conserva el documento solicitado.



search cuenta intentos, conserva document_id y top_k y descarta duplicados u otros documentos. Máximo 2; rango 1..2.


rewrite_query quita puntuación y palabras frecuentes ES/EN, sin LLM. La pregunta original permanece intacta.

Azure AI Search devuelve texto, fuentes, páginas y scores. La recuperación es textual, sin embeddings.

Solo repite con términos y una alternativa diferente. Sin alternativa o intentos: aviso; no abre OpenAI.

Preparar contexto y estado

Presupuesto en caracteres del contenido; el contexto preparado acompaña a la respuesta final.



12.000 caracteres de content por defecto; no cuenta pregunta, metadatos, JSON ni tokens.

Estado: query, search_question, context, prompt, draft, issues, answer, contadores y request_id.

El prompt mantiene la pregunta original. La respuesta devuelve las copias preparadas; originales intactos.

El estado puede contener texto privado. Sin clientes, credenciales ni checkpoints durables.

El contexto y la pregunta original pasan a generate en la hoja 5. El estado solo vive durante esta ejecución.

Hoja 4 / 8

Fuente Mermaid · A4 horizontal

Generación delegada en Azure OpenAI

El primer generate abre OpenAI; las reparaciones reutilizan el cliente y la credencial del usuario.



OBO: token de la API + credencial del registro FastAPI. Scope: <https://cognitiveservices.azure.com/.default>.


POST /openai/v1/chat/completions; model = deployment;
max_completion_tokens = 2000 por llamada.

RBAC del usuario: Cognitive Services OpenAI User sobre la cuenta Azure OpenAI.

Sin contexto no abre OpenAI. Repara con el mismo cliente; el token puede renovarse. Cierre: hoja 7.

Comprobar citas y reparar

Las reglas locales comprueban fuente y página; no demuestran el respaldo factual de cada afirmación.



Exige texto no vacío, ≤16.000 caracteres y al menos una cita. Fuente y página deben estar en el contexto.

verify_citations=false acepta el borrador. Por defecto: 2 generaciones en total; rango 1..3.


Cita de solo fuente: exige un fragmento page=None. No demuestra respaldo factual de cada afirmación.

repair prepara prompt con contexto, borrador e issues. generate reutiliza el cliente y la credencial.

La reparación vuelve a generate en la hoja 5. La respuesta aceptada o la abstención termina en la hoja 7.

Salida, abstención y errores

Abstención: HTTP 200. Un error interrumpe el grafo y mantiene los errores controlados de FastAPI.



HTTP 200: respuesta con contexto; aviso sin contexto []; o aviso de citas inválidas con contexto.


401: JWT/token. 403: scope/azp, OBO o RBAC Search. 503: configuración o indisponibilidad.

context devuelve solo copias preparadas. ExitStack cierra OpenAI; la dependencia cierra Search, también ante error.

OpenAI HTTP 403/429 → 502 rag_provider_error; OBO rechazado → 403. Sin reintento HTTP ni cambio de identidad.

Configuración, trazas y demostración

Settings configura API y evaluación; la demostración offline utiliza opciones predeterminadas.



APP_RAG_MAX_SEARCH_ATTEMPTS=2 (1..2);
APP_RAG_MAX_GENERATION_ATTEMPTS=2 (1..3).

APP_RAG_VERIFY_CITATIONS=true; APP_RAG_TRACE_ENABLED=true.
La demo usa defaults sin leer .env ni Settings.

APP_RAG_MAX_CONTEXT_CHARACTERS=12000 (1..60000); limita
caracteres del contenido.

Trazas: request_id, node, outcome, intentos, duration_ms; sin pregunta,
contexto, respuesta ni tokens.